

# 混合学习 - 数值方法解决二维高频 Helmholtz 方程的系统方案

## 引言

### 二维Helmholtz方程

$$-\Delta u(x, y) - k^2 u(x, y) = q(x, y), \quad (x, y) \in \Omega := [-1, 1] \times [-1, 1], \quad u|_{\partial\Omega} = 0,$$

描述电磁辐射、声波和地震波等的稳态波动问题。在给定的子任务中，**第 1 题**要求使用深度学习方法求解常波数情形 ( $k = 4$ ) 的解  $u$ ，**第 2 题**要求在高波数 ( $k = 100, 500, 1000$ ) 下快速求解。高频 Helmholtz 方程具有以下数值困难：

1. **高度振荡与污染效应**：波长  $\lambda = 2\pi/k$  很短，需要每波长  $> 10$  个网格点，导致维度灾难；离散误差随  $k$  指数增长，常规有限元/差分收敛性恶化。
2. **大规模不定线性系统**：离散矩阵复杂，Krylov 方法收敛缓慢，需要特定预条件器才能加速。
3. **边界处理复杂**：高频情况下的吸收边界条件 (PML) 或者无限域辐射条件难以保证精度。

为了在高频场景下兼顾精度、效率和泛化能力，本文提出一套**混合学习-数值方法**，综合了**Neumann 系列神经算子 (NSNO)**、**多尺度网络 UNO/FNO**、**傅立叶/正弦基和平面波激活**、**PDE 物理约束与 Tikhonov 正则化**、**预条件 GMRES 细化**以及**基本解特征**等技术，从而实现对一类 Helmholtz 方程的快速求解。下文详细阐述每个组成部分的原理、相互作用及实现步骤，并引用最近文献支持其有效性。

## 理论基础与关键技术

### 1. Neumann 系列神经算子 (NSNO)

传统神经算子如 **Fourier Neural Operator (FNO)** 通过在频域参数化积分核学习参数到解的映射，可在不同网格上泛化，并相较传统求解器实现数个数量级的加速<sup>①</sup>。然而在高波数 Helmholtz 方程中，源项与介质系数耦合导致直接学习算子困难。

**NSNO**利用 Helmholtz 方程的**Neumann 系列解表示**来解耦这一耦合。具体来说，将非齐次方程写成形式  $(I - \mathcal{K})u = f$ ，其中  $\mathcal{K}$  为包含介质系数的紧算子，解可以表示为 Neumann 级数：

$$u = (I + \mathcal{K} + \mathcal{K}^2 + \cdots)f.$$

NSNO 将每一项视为在均匀介质中求解不同源项的 Helmholtz 方程<sup>②</sup>。这样源项  $f$  与介质系数完全解耦；通过截断级数，仅需学习少数几项的算子即可逼近整体解<sup>②</sup>。NSNO 使用 **UNO**（将 **Fourier Neural Operator** 与 **U-Net** 结合的多尺度网络）作为基础模块以捕捉解的多尺度特性<sup>③</sup>。文献实验表明 NSNO 相比 FNO 在大波数情形的相对误差至少降低 60%，计算成本降低 50%，且所需训练数据更少<sup>④</sup>。

## 2. 多尺度网络 UNO/FNO 与正弦/傅立叶基

**FNO**通过对输入函数做傅立叶变换，并在频域进行卷积来表示积分核，天然适用于周期或平滑结构<sup>①</sup>。对于具有 Dirichlet 边界的正方形区域，采用**正弦基函数** $\sin(m\pi(x+1)/2)\sin(n\pi(y+1)/2)$ 可自动满足零边界条件，并方便结合傅立叶变换。

为了适应高波数振荡，还可在网络中加入**平面波激活函数**。文献指出，采用复指数  $e^{ik \cdot x}$  激活的网络（PWNN）在 Helmholtz 方程上比使用普通激活函数或 SIREN 更精确，并能在相同采样下显著降低误差<sup>⑤</sup>。因此本文在 UNO 模块中增设平面波支路，帮助表示高频波场。

## 3. 物理约束与 Tikhonov 正则化

数据驱动方法在高频 Helmholtz 问题中若完全依赖监督数据，容易过拟合并缺乏物理一致性。**Physics-informed neural operator (PINO)** 和 **PICNO** 等方法通过在损失函数中加入 PDE 残差、边界条件和能量守恒项，在减少训练数据的同时显著提升泛化能力<sup>⑥</sup>。我们将这一思想应用于 NSNO，将 Helmholtz 方程残差和 Dirichlet 条件作为训练损失的重要部分。

同时，为稳定学习过程并避免不适定问题，引入 **Tikhonov 正则化**。学习基础解算子的 LbNM 方法使用 Tikhonov 正则化稳定地学习解算子，并利用基本解信息（Helmholtz 方程的 Hankel 函数）快速更新边界解<sup>⑦</sup>。本文将 Tikhonov 正则作为网络权重的正则项，控制参数范数，并在物理残差与监督损失之间平衡。

## 4. 基本解与 Hankel 函数特征

二维 Helmholtz 方程的自由空间格林函数是 Hankel 函数  $G_k(x, y) = \frac{i}{4}H_0^{(1)}(k|x-y|)$ 。LbNM 方法强调用基本解作为学习字典，使算子学习具有解释性和泛化性<sup>⑦</sup>。在我们的方案中，基本解特征可以作为网络输入通道或卷积核的一部分，在处理点源或局部散射时尤其有效。对于恒定介质和周期边界，我们主要用正弦/傅立叶基；若将来扩展到外场散射或不规则边界，可启用 Hankel 近场特征支路。

## 5. 预条件迭代器：移位拉普拉斯与扫掠预条件

神经算子虽然可以快速给出近似解，但在高波数情况下仍可能产生相位或振幅偏差。为保证最终精度，我们在推断阶段使用少量**预条件 Krylov 迭代**对神经算子输出进行细化。典型方法是**移位拉普拉斯预条件**：将 Helmholtz 算子  $-\Delta - k^2$  替换为  $-\Delta - (k^2 + i\varepsilon)$  的倒数作为预条件器，从而降低系统的反射和不定性<sup>⑧</sup>。配合 **GMRES** 迭代，几步即可显著降低残差。在二维情况下，也可使用**扫掠预条件**（sweeping preconditioner）沿某一空间方向逐层消元，具有线性复杂度。

# 训练数据与采样策略

## 1. 制造解生成监督样本

题目给出源项

$$q(x, y) = -(a_1\pi)^2 \sin(a_1\pi x) \sin(a_2\pi y) - (a_2\pi)^2 \sin(a_1\pi x) \sin(a_2\pi y) - k^2 \sin(a_1\pi x) \sin(a_2\pi y),$$

其中  $a_1 = 1, a_2 = 3$ 。显然真解为  $u^*(x, y) = \sin(\pi x) \sin(3\pi y)$ 。此构造法（制造解）既适合监督学习也适合作为 PINN 的验证点。为扩展泛化，可随机选取  $a_1, a_2, k$  在一定范围内生成参数族。

## 2. 采样策略

- **域内采样**：在  $[-1, 1]^2$  采用 Sobol 或 Halton 低差异序列产生  $N_{\text{int}}$  个点；对高波数应在边界层和可能激波区（此题为光滑波）适当过采样。对时间独立问题无需时间采样。
- **边界采样**：在四条边各取  $N_{\text{bdry}}$  个点，用于 Dirichlet 边界损失；若实施吸收边界/PML，可相应采样其厚度区域。
- **参数采样**：为训练跨多个  $k$ ，选择  $k$  在  $[1, k_{\text{max}}]$  上分层抽样。课程式训练可以先从低波数开始逐步增加高波数。
- **残差驱动补点 (RAR)**：训练过程中定期评估 PDE 残差热图，在残差最大区域新增采样点，从而自适应捕捉局部细节。

## 完整方案流程

### 1. 网络设计与损失函数

1. **NSNO/UNO 主干**：输入包括介质参数（常数取 1）、源项特征  $q$ 、波数  $k$ 、空间坐标  $(x, y)$  以及可选的 Hankel/平面波特征；输出为解  $u(x, y)$ 。基础模块 UNO 由多层 FNO 和 U-Net 组成，可在频域与空间域交替提取全局和局部特征<sup>3</sup>。
2. **平面波支路**：并行分支使用复指数激活  $e^{ik \cdot x}$  学习传播方向，尤其适合高频振荡<sup>5</sup>。
3. **PDE 物理损失**：
4. 领域残差损失： $L_{\text{PDE}} = \| -\Delta u - k^2 u - q \|_{L^2(\Omega)}^2$ 。
5. 边界损失： $L_{\text{BC}} = \| u|_{\partial\Omega} \|_{L^2}^2$ 。
6. 监督损失（若采用制造解）： $L_{\text{data}} = \| u - u^* \|_{L^2}^2$ 。
7. **正则化项**：加入 Tikhonov 正则  $\alpha \| \theta \|_2^2$  控制网络权重范数，增强稳定性<sup>7</sup>。
8. **总损失**： $L = w_1 L_{\text{data}} + w_2 L_{\text{PDE}} + w_3 L_{\text{BC}} + \alpha \| \theta \|_2^2$ 。权重  $w_i$  根据训练阶段动态调整：初始阶段重视监督数据，中后期逐渐强调 PDE 约束。

### 2. 训练步骤

1. **数据准备**：生成若干不同  $k$  值的训练样本集，包含制造解  $u^*(x, y)$  或数值解，以及对应源项  $q$ 。采样点数可以根据波数规模调整，高波数需更多内点。
2. **课程式训练**：从较小波数开始训练网络，使其掌握低频特征后再逐步增加更大  $k$ 。
3. **残差驱动补点**：每隔一定步数，计算当前网络在一批探测点上的 PDE 残差，按照残差的分位数选择热点区域重新采样并加入训练集。该策略可显著提升高频区域的精度。
4. **梯度稳定化**：使用梯度裁剪及自适应学习率；同时对不同损失项采用动态权重调整（GradNorm 或基于物理量的自适应权重），避免梯度爆炸或消失。

### 3. 推断与细化

1. **NSNO 推断**：在给定新波数  $k$ （如 4、100、500、1000）和源项下，通过训练好的 NSNO 网络一次前向计算获得初始预测  $u_0$ 。由于 NSNO 以近似 Neumann 级数方式表达解，其推断时间与网络大小和输入网格直接相关，不随波数显著增加。
2. **预条件 GMRES 细化**：将初始预测  $u_0$  作为初始向量，求解线性方程  $(-\Delta - k^2)u = q$  的残差。使用移位拉普拉斯预条件器  $(-\Delta - (k^2 + i\varepsilon))^{-1}$  或扫描预条件，对残差进行 1-3 步 GMRES 迭代即可明显降低误差<sup>8</sup>。此阶段成本远低于从零迭代求解。
3. **误差评估与后处理**：计算相对  $L^2/L^\infty$  误差、守恒量和能量残差；若误差超出阈值，可进一步迭代或调整预条件器参数。

## 学术支撑与可行性分析

- **NSNO 优势**: NSNO 通过 Neumann 系列将解算子拆解为简单算子的叠加, 使源项和介质解耦<sup>2</sup>; UNO 结合 FNO 与 U-Net 捕捉多尺度特征<sup>3</sup>; 在高波数情况下, 实验证明其相对误差至少下降 60%, 计算成本降低 50%, 且对训练数据需求更低<sup>4</sup>。
- **FNO 的泛化与速度**: FNO 直接在频域参数化积分核, 具有网格不变性和高效推断能力, 在学习 PDE 算子方面实现了比传统数值方法高三个数量级的速度提升<sup>1</sup>。
- **平面波激活与振荡表达**: 平面波激活网络利用复指数捕捉传播方向, 优于普通激活函数或 SIREN, 特别适合 Helmholtz 方程的振荡解<sup>5</sup>。
- **PICNO/物理约束的必要性**: 在神经算子损失中加入 PDE 残差等物理项, 可大幅减少对真实解数据的依赖并提升高频泛化能力<sup>6</sup>。
- **Tikhonov 正则与基本解**: 学习基于基本解的解算子并施加 Tikhonov 正则, 可稳定地学习解算子并快速更新边界输入<sup>7</sup>。利用基本解信息可以提高模型的解释性和泛化能力。
- **预条件细化的重要性**: 移位拉普拉斯预条件器和扫描预条件器能显著降低高频 Helmholtz 系统的条件数, 结合 GMRES 可以快速收敛<sup>8</sup>。在神经算子预测的基础上做少量迭代, 能够修正残留的相位和振幅误差。

## 实现建议

1. **数据生成示例** (制造解):
2. 设置  $k \in [1, 200]$  的训练集合; 对每个  $k$  在  $[-1, 1]^2$  生成  $N_{\text{int}} \approx 10^4$  Sobol 点及  $N_{\text{bdry}} \approx 2000$  边界点。
3. 计算真解  $u^*(x, y) = \sin(\pi x) \sin(3\pi y)$  以及源项  $q$ 。
4. 保存  $(x, y, k, q, u^*)$  作为监督数据; 另行保存无标签配点用于 PDE 残差。
5. **网络与训练**:
6. UNO 模块采用 4-6 个 FNO 层与 U-Net 跳跃连接, 通道数从 32 增加至 128。
7. 平面波支路使用少量可学习的传播方向向量; 特征通过与 UNO 输出拼接。
8. 训练初期取权重  $w_{\text{data}} : w_{\text{PDE}} : w_{\text{BC}} = 1 : 1 : 2$ , 随后降低  $w_{\text{data}}$  至 0.3-0.5; 正则参数  $\alpha$  可取  $10^{-4}$ 。
9. 每隔 500 迭代执行残差驱动补点 (采样上千新点)。
10. **推断与精修**:
11. 对于目标波数  $k = 4$ : 网络预测即可达到高精度; 若必要, 做一两次预条件迭代。
12. 对于高波数  $k = 100, 500, 1000$ : 使用训练好的 NSNO 前向得到初值  $u_0$ , 随后进行 1-3 次 GMRES 迭代, 其中移位拉普拉斯预条件的参数  $\varepsilon$  可选  $\varepsilon = 0.5k$ 。

## 结论

本文系统整理了一套适用于二维高频 Helmholtz 方程的**混合学习-数值求解方案**。核心在于:

- 使用 **Neumann 系列神经算子 (NSNO)** 结合 **UNO/FNO** 多尺度结构学习跨波数的解算子, 充分利用 Neumann 级数解耦源项与介质<sup>2</sup>;
- 引入 **平面波激活** 和 **正弦/傅立叶基** 捕捉高频振荡<sup>5</sup>;
- 在训练中加入 **PDE 残差**、**边界条件** 以及 **Tikhonov 正则化** 以保证物理一致性和稳定性<sup>6</sup><sup>7</sup>;
- 在推断阶段用 **预条件 GMRES** 对神经算子输出进行少量精修, 提高高波数精度<sup>8</sup>。

这一方案兼具理论支撑与工程可行性: NSNO/UNO 提供高速、跨参数的推断能力; 预条件迭代保障高频精度; 物理约束提高泛化并减少数据需求。对同类边值问题 (不同  $a_1, a_2, k$  或不同源项) 也具有良好适用性。通过合理的训练数据生成和残差驱动采样, 可以在有限样本下实现可靠且高效的高频 Helmholtz 求解, 为将深度学习与传统数值算法结合提供了范例。

- 1 [2010.08895] Fourier Neural Operator for Parametric Partial Differential Equations  
<https://ar5iv.labs.arxiv.org/html/2010.08895>
- 2 3 4 NSNO: Neumann Series Neural Operator for Solving Helmholtz Equations in Inhomogeneous Medium <sup>\*</sup>  
<https://arxiv.org/html/2401.13494v1>
- 5 [2012.13870] A Neural Network with Plane Wave Activation for Helmholtz Equation  
<https://ar5iv.labs.arxiv.org/html/2012.13870>
- 6 An effective physics-informed neural operator framework for predicting wavefields  
<https://arxiv.org/html/2507.16431v1>
- 7 Learning based numerical methods for Helmholtz equation with high frequency  
<https://arxiv.org/html/2401.09118v1>
- 8 Shifted Laplace and related preconditioning for the Helmholtz equation  
<https://www.maths.dur.ac.uk/lms/101/talks/0514graham.pdf>